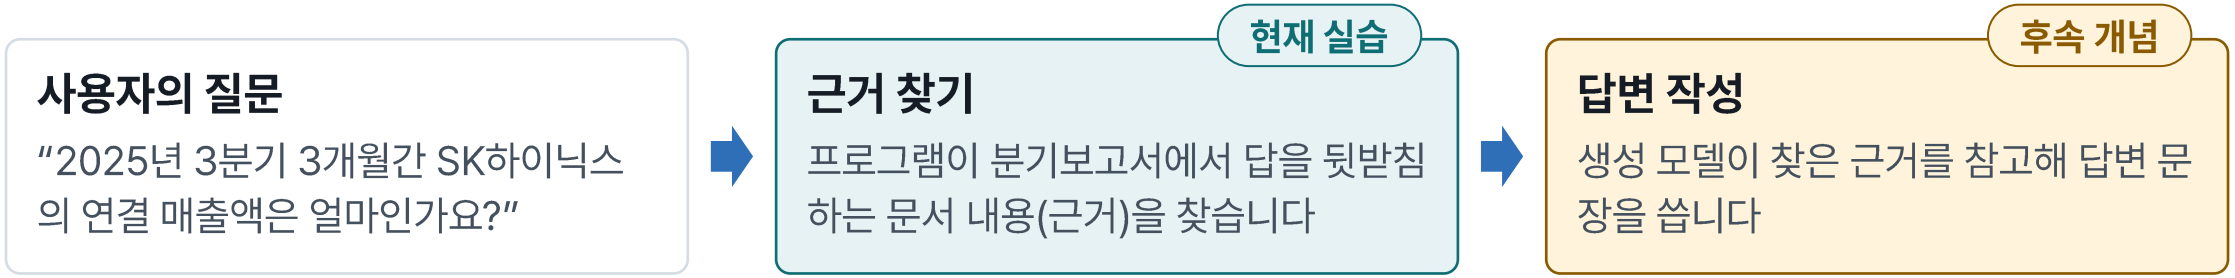
문서에서 답의 근거를 찾는 RAG

SK하이닉스 분기보고서에서 매출액을 찾는 질문 하나를 끝까지 따라갑니다

문서에서 답의 근거를 찾는 RAG

SK하이닉스 분기보고서에서 매출액을 찾는 질문 하나를 끝까지 따라갑니다

사용자는 SK하이닉스 분기보고서(2025년 3분기, DART 공시) MD 파일에서 매출액을 찾고 싶습니다. RAG 프로그램은 질문에 관련된 문서 부분을 찾고, 생성 모델이 그 부분을 참고해 답하도록 연결합니다. **이번 실습의 프로그램은 문서 준비, 근거 검색, 검색 결과 검사까지 다룹니다.**



'근거'는 답을 뒷받침하는 문서 내용입니다. 이 교안에서는 분기보고서의 매출액 표가 그 근거입니다.

한국폴리텍대학교 하이테크 2026-2 · RAG 개요 교안 · 수정본 2026-09-21 · 실습 자료 rag_exam(NB01~NB05)

범위	이번 실습은 문서 준비 → 근거 검색 → 검색 결과 검사까지 합니다. 답변 문장 작성은 뒤에서 개념으로만 설명합니다.

다음 → 이 교안을 읽고 나면 무엇을 설명할 수 있는지부터 봅니다

이 교안을 읽고 설명할 수 있는 네 가지

외울 용어 목록이 아니라, 학생이 혼자 설명할 수 있어야 할 네 가지입니다.

① 입력 설명

학생은 사용자가 넣는 **질문**과 **기간**을 구분해 설명할 수 있습니다.

→ 마지막 활동 2번에서 확인합니다

② 역할 연결

학생은 Python 프로그램, 임베딩 모델, ChromaDB가 맡는 일을 연결할 수 있습니다.

→ 마지막 활동 1번에서 확인합니다

③ 원문 확인

학생은 검색된 표에서 **기간·단위·출처**를 확인할 수 있습니다.

→ 마지막 활동 3번에서 확인합니다

④ 실습 범위

학생은 답변 작성이 이번 실습의 어느 범위에 있는지 설명할 수 있습니다.

→ 마지막 활동 4번·5번에서 확인합니다

네 가지는 마지막 활동 '실제 자료로 전체 흐름을 확인해 보세요'의 문항과 하나씩 이어집니다. 활동의 정답과 이유는 바로 다음 화면에 있어서 학생이 혼자 확인할 수 있습니다.

기준 '말할 수 있다'가 기준입니다. 전체 구현이나 실무 완성을 약속하지 않습니다.

다음 → 사용자가 실제로 넣는 질문 하나를 먼저 봅니다

분기보고서에서 3분기 매출액 찾기

사용자의 질문은 하나입니다. 답은 분기보고서의 표 한 행에 있습니다.

사용자의 질문 "2025년 3분기 3개월간 SK하이닉스의 연결 매출액은 얼마인가요?"

원문 일부 재구성

절 2-2. 연결 포괄손익계산서 · 보고 기간 2025.01.01~2025.09.30 · (단위 : 백만원)

연결 포괄손익계산서	제 78 기 3분기 3개월	제 78 기 3분기 누적
매출액	24,448,929	64,320,022

매출액 행에는 '3개월' 값과 '누적' 값이 함께 있습니다. 학생은 질문의 기간에 맞는 열을 골라야 합니다. 두 값은 서로 다른 기간의 금액입니다.

제공된 실습용 원문 000660_SK하이닉스_2025Q3_원문발췌_실습용_v1.0.md의 연결 포괄손익계산서에서 제목·기간·단위·매출액 행만 골라 다시 구성했습니다. 외부 최신 공시를 새로 확인한 값이 아닙니다.

표 옆의 말뜻

공시 회사가 공개한 보고 자료입니다.

연결 회사와 종속기업의 실적을 함께 집계한 기준입니다.

3분기 3개월 여기서는 2025년 7~9월입니다.

누적 여기서는 2025년 1~9월을 합친 기간입니다.

백만원 표의 숫자 1이 1,000,000원을 뜻합니다.

확인 두 값 중 하나가 틀린 값은 아닙니다. 질문이 3개월을 물으므로 학생은 3개월 열을 읽습니다.

다음 → 답변 문장만 받으면 무엇이 부족한지 봅니다

답변 옆에 원문을 두는 이유

생성 모델은 질문을 받아 답변 문장을 쓰는 모델입니다. 답변 문장만 보면 무엇이 부족한지 살펴봅니다.

설명용 비교 사용자가 받는 화면을 두 가지로 나눈 설명용 구성입니다. 실제로 생성해 비교한 실험이 아닙니다.

답변 문장만 보는 경우

사용자가 받는 것: "3분기 매출액은 24,448,929백만원입니다."

사용자가 알기 어려운 것: 이 금액이 분기보고서의 어느 표**, 어느 열**에서 나왔는지. 3개월 값인지 누적 값인지도 답변만으로는 확인하기 어렵습니다.

원문 표와 출처도 보는 경우

사용자가 받는 것: 답변 문장 + 매출액 행이 있는 표 + 출처(파일명, 절 제목)

사용자가 할 수 있는 것: 답변의 **금액·기간·단위**를 원문 표와 직접 비교합니다.

프로그램이 관련 원문과 출처를 함께 보여 주면, 사용자는 답변을 원문과 비교할 수 있습니다. 여기서 **출처**는 원문을 다시 찾을 수 있는 파일명과 절 제목입니다. 출처가 있어도 비교는 사람이 합니다.

핵심 답이 그럴듯한지보다, 사용자가 무엇을 근거로 한 답인지 확인할 수 있는지가 중요합니다.

다음 → 그런데 새 분기보고서가 나오면 프로그램은 무엇을 해야 하는지 봅니다

새 문서가 생기면 프로그램이 해야 할 일

생성 모델이 어떤 분기보고서를 학습했는지는 사용자가 답변만 보고 확인하기 어렵습니다.

① 확인하려는 문서

예: 2025년 3분기 분기보고서 MD 파일. 사용자는 이 문서의 내용으로 답을 확인하고 싶습니다.

② 사용할 수 있는 자료인지 확인

회사 내부 문서라면 사용자가 읽을 수 있는 자료인지 먼저 확인합니다.

③ 필요한 내용 전달

프로그램은 이번에 확인할 분기보고서 내용을 생성 모델의 입력으로 제공할 수 있습니다.

사용자가 새 문서를 제공하면 생성 모델은 그 내용을 입력으로 읽을 수 있습니다. **이 실습은 그중 '문서에서 필요한 부분을 찾는 과정'을 다룹니다.** 회사 내부 문서를 사용할 때는 사용자가 읽을 수 있는 자료인지도 확인해야 합니다.

②의 권한 확인은 별도 설계가 필요한 일입니다. 이번 노트북(NB01~NB05)에는 사용자 권한을 확인하는 코드가 없습니다.

정리 모델이 새 글을 못 읽는 게 아닙니다. 필요한 문서를 프로그램이 찾아서 전달해야 합니다.

다음 → 그 일을 나누어 맡는 담당들을 봅니다

같은 프로그램 안에서도 맡는 일이 다릅니다

'프로그램'은 이 실습의 Python 프로그램입니다. 프로그램이 요청을 보내는 담당마다 받는 것과 돌려주는 것이 다릅니다.

담당	받는 것	하는 일	돌려주는 것	이번 실습
Python 프로그램	MD 파일, 사용자의 질문과 기간	파일을 읽고, 글을 나누고, 각 도구에 요청을 보내고, 결과를 표로 묶습니다	청크 파일, 검색 결과 표	구현
Ollama	글과 모델 이름	임베딩 모델을 실행하고 요청과 응답을 연결합니다	임베딩 모델의 결과	구현
임베딩 모델 (qwen3-embedding:0.6b)	글 조각 또는 질문	글을 비교할 숫자 목록으로 바꿉니다	숫자 목록	구현
ChromaDB	청크·숫자·출처 정보 / 질문 숫자와 기간 조건	저장하고, 숫자를 비교해 후보 글을 찾습니다	후보 글 최대 5개와 출처 정보	구현
생성 모델	질문과 근거	근거를 참고해 답변 문장을 씁니다	답변 문장	후속 개념

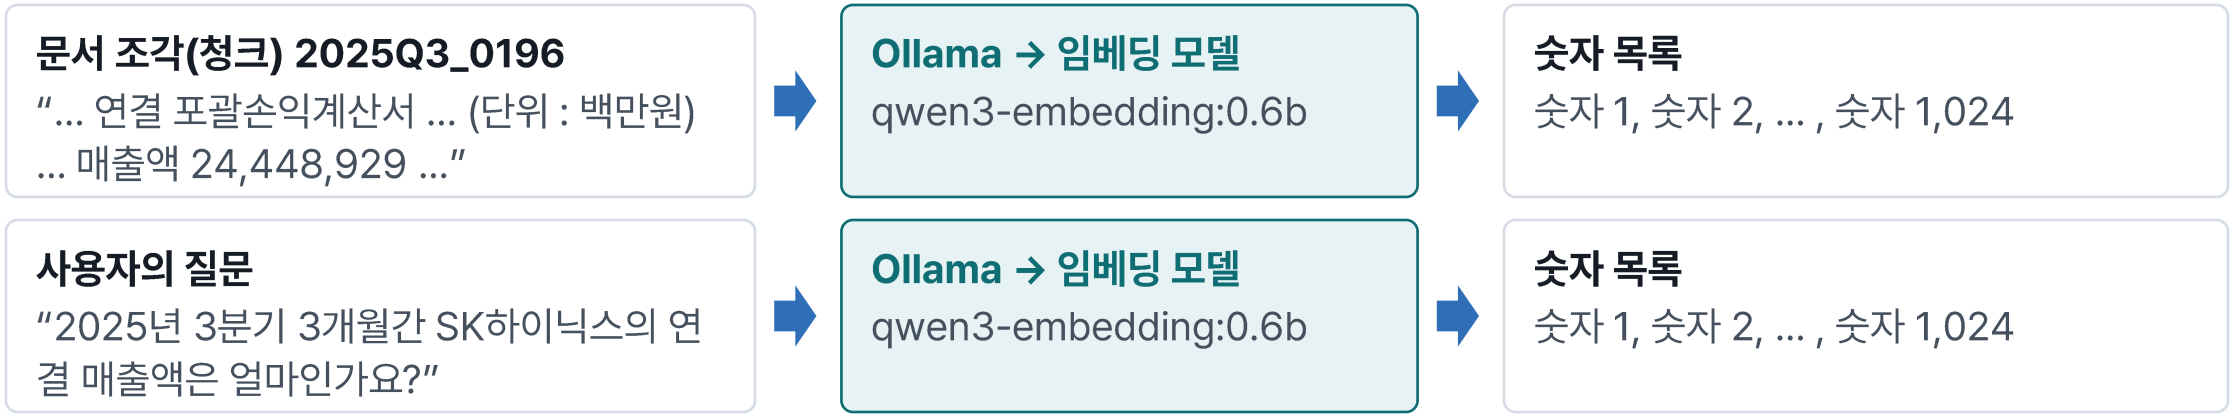
> **주의** '모델'이라는 한 상자에 임베딩과 답변 작성을 함께 넣지 않습니다. 두 모델은 받는 것도 돌려주는 것도 다릅니다.

다음 → 이번 실습의 임베딩 모델이 실제로 무엇을 만드는지 봅니다

이번 임베딩 모델은 숫자 목록을 만듭니다

프로그램은 Ollama에 글과 모델 이름을 보냅니다. 문서 조각과 질문에 같은 모델을 씁니다.

설명용 도식 '숫자 1, 숫자 2, …'는 모양만 설명하는 표시입니다. 임의로 지어낸 소수값은 적지 않았습니다.



이 임베딩 모델은 글을 비교할 숫자 목록으로 바꿉니다. 프로그램은 문서 조각과 질문에 **같은 모델**을 사용합니다. 그래야 ChromaDB가 같은 기준으로 비교할 수 있습니다.

1,024는 현재 저장 출력에서 확인한 숫자 목록의 길이입니다. 글자 수, 토큰 수, 청크 수가 아닙니다.

ChromaDB가 두 숫자 목록을 비교해 질문과 가까운 후보 글을 찾습니다

> **구분** 임베딩은 요약문·번역문·금액 답변이 아닙니다. 비교에 쓰는 숫자 목록입니다.

다음 → 어떤 기능이 어떤 일을 맡는지 직접 나누어 봅니다

활동 1. 이 일을 맡는 기능 찾기

아래 네 행동을 'Python 프로그램 / 임베딩 모델 / ChromaDB / 생성 모델'과 연결해 보십시오.

활동

가. 어떤 기능이 글을 받아 비교할 숫자 목록을 만듭니까?

나. 어떤 기능이 질문의 숫자와 기간 조건을 받아 후보 글을 돌려줍니까?

다. 어떤 기능이 파일을 읽고, 도구에 요청하고, 받은 결과를 표로 묶습니까?

후속 개념

라. 어떤 기능이 질문과 근거를 받아 답변 문장을 씁니까?

담당 후보

Python 프로그램 → ____

임베딩 모델 → ____

ChromaDB → ____

생성 모델 → ____

혼자 읽는 학생은 종이에 '가~라'의 담당을 적은 뒤 다음 화면의 해설과 비교해 보십시오. 한 담당에 여러 행동이 갈 수도 있고, 하나도 없을 수도 있습니다.

진행 정답과 이유는 바로 다음 화면에 있습니다. 라의 기능은 이번 노트북에 없고 뒤에서 개념으로 설명합니다.

다음 → 정답과 '받는 것 → 돌려주는 것'을 확인합니다

해설 1. 입력과 결과를 보면 역할을 구분할 수 있습니다

각 행동의 '받는 것 → 돌려주는 것'이 정답의 이유입니다.

해설

행동	담당	받는 것 → 돌려주는 것
가. 비교할 숫자 목록 만들기	**임베딩 모델**	글(청크 또는 질문) → 숫자 목록. Python 프로그램이 Ollama를 거쳐 이 요청을 보냅니다.
나. 후보 글 돌려주기	**ChromaDB**	질문의 숫자 목록 + 기간 조건 → 저장해 둔 글 조각과 출처 정보(최대 5개)
다. 읽고, 요청하고, 표로 묶기	**Python 프로그램**	파일과 각 도구의 응답 → 코드에 적힌 순서로 연결한 결과 표
라. 답변 문장 쓰기	**생성 모델 (후속 개념)**	질문 + 근거 → 새로 쓴 답변 문장. 이번 노트북에는 이 요청이 없습니다.

ChromaDB의 검색 결과는 **저장해 둔 글 조각**이에요. 생성 모델의 결과는 **새로 쓴 답변 문장**이에요. 이 둘은 서로 다른 결과입니다. Python 프로그램은 스스로 판단하지 않고 코드에 적힌 순서대로 요청과 결과를 연결합니다.

> **확인** 검색 결과(저장해 둔 글)와 생성 결과(새로 쓴 문장)를 구별하면 뒤의 흐름을 읽기 쉽습니다.

다음 → 그런데 문서 전체를 통째로 보내면 안 되는지 봅니다

문서 전체를 보내는 방식의 조건

보낼 수는 있습니다. 다만 확인할 조건이 있습니다.

설명용 비교

분기보고서 전체를 보내는 경우

프로그램이 2025년 3분기 분기보고서 MD 파일 전체를 생성 모델에 보냅니다.

확인할 점: 모델이 한 번에 처리할 수 있는 분량의 한도가 있습니다. 긴 입력만큼 처리 부담이 늡니다. 사용자가 확인할 근거가 문서 전체로 넓어집니다.

관련 부분을 먼저 찾아 보내는 경우

프로그램이 매출액 표가 있는 부분(연결 포괄손익계산서 청크)을 먼저 찾아 보냅니다.

좋은 점: 사용자가 확인할 근거가 좁혀집니다. 조건: 필요한 부분을 놓치지 않게 검색해야 합니다. 검색이 놓치면 근거 없이 답하게 됩니다.

프로그램이 관련 부분을 먼저 찾으면 사용자가 확인할 근거를 좁힐 수 있습니다. 전체를 보내는 방식이 항상 나쁜 것도, 관련 부분만 보내면 답이 항상 같은 것도 아닙니다.

핵심 검색은 '필요한 부분을 놓치지 않으면서, 사용자가 확인할 범위를 좁히는 일'이에요.

다음 → 글의 양을 세는 세 가지 말을 구분합니다

글자 수, 토큰, 청크는 서로 다른 말입니다

셋 다 '글의 양'과 관련되지만, 세는 주체와 쓰임이 다릅니다.

글자 수

사람이 세는 단위예요. 이번 분할 코드는 토큰이 아니라 글자 수를 기준으로 글을 나눕니다.

토큰

모델이 글을 처리할 때 쓰는 단위예요. 한 문장도 여러 토큰으로 나뉘고, 모델마다 나누는 방식이 다릅니다. 모델의 입력 한도는 '한 번에 다룰 수 있는 토큰 범위'예요

청크

프로그램이 검색하려고 긴 글을 나눈 작은 조각이에요. 조각마다 파일명·기간·절 제목을 붙입니다.

설명용 도식 토큰의 모양을 설명하는 예입니다. 실제 임베딩 모델이 이 문장을 나눈 결과가 아닙니다.

"3분기 매출액은 얼마인가요?" → 3 | 분기 | 매출 | 액 | 은 | 얼마 | 인가요 | ?

한 문장이 여러 토큰으로 나뉩니다. 글자 수와 토큰 수는 같지 않습니다. 그래서 글자 수 700을 토큰 수로 읽으면 안 됩니다.

주의 700은 글자 수 설정이고, 1,024는 숫자 목록의 길이입니다. 둘 다 토큰 수가 아닙니다.

다음 → 이번 분할 설정을 그림으로 봅니다

이번 분할 설정은 700자, 겹침 200자입니다

프로그램이 긴 글을 어떻게 잘라 청크를 만드는지 그림으로 봅니다.

설명용 도식

원문 본문 (한 절의 글이 길게 이어집니다)

청크 1 · 본문 최대 700자

청크 2 · 본문 최대 700자

청크 3 · 본문 최대 700자

← 겹침 200자 →

프로그램이 청크 앞에 붙이는 정보

회사와 기간(SK하이닉스 2025Q3), 절 제목, 표라면 표 머리글과 단위 줄을 붙입니다.

그래서 최종 청크는 700자보다 길 수 있습니다. 학생은 조각만 보아도 어떤 표의 어느 기간인지 확인할 수 있습니다.

저장된 청크 청크 2025Q3_0196의 앞부분 (artifacts/chunks.jsonl에 저장된 실제 글)

SK하이닉스 2025Q3 / III. 재무에 관한 사항 > 2-2. 연결 포괄손익계산서 / | 연결 포괄손익계산서 | … | (단위 : 백만원) | | 제 78 기 3분기 3개월 | 제 78 기 3분기 누적 | … | 매출액 (주4,21,28) | 24,448,929 | 64,320,022 | …

확인 모든 표가 통째로 한 청크에 들어간다고 보장하지는 않습니다. 그래서 학생은 검색된 청크의 표 머리글과 단위를 함께 읽습니다.

다음 → 이 담당들을 7단계 지도에 올립니다

질문 하나가 지나가는 전체 흐름

앞에서 본 담당들을 7단계 지도에 올렸어요(이 교안의 설명용 지도). 맨 아래 칸은 이번 실습의 노트북 대응입니다.

①② 자료 준비 — 질문 전에 미리		③④ 질문별 검색 — 질문마다		⑤⑥ 후속 답변 구성 — 후속 개념		⑦ 사람
① 문서 나누기	② 숫자 만들고 저장하기	③ 질문과 기간 입력하기	④ 후보 글 찾기	⑤ 질문·근거 전달하기	⑥ 답변 작성·출처 표시	⑦ 사람이 확인하기
프로그램이 MD 문서를 읽고 청크를 만듭니다.	임베딩 모델이 숫자를 만들고, 프로그램이 글·숫자·출처를 ChromaDB에 저장합니다.	사용자가 질문과 기간(2025Q3)을 입력합니다.	임베딩 모델이 질문 숫자를 만들고, ChromaDB가 기간에 맞는 후보를 찾습니다.	후속 답변 프로그램이 질문·근거·출처를 생성 모델에 보냅니다.	생성 모델이 답변을 쓰고, 답변 프로그램이 근거 출처를 표시합니다.	사용자가 원문에서 금액·기간·단위를 비교합니다.
NB01	NB02	NB03 (테스트는 CSV)	NB03·NB05	후속 개념	후속 개념	검색 원문 확인은 지금도 합니다

비유 사람이 목차에서 찾고 → 그 쪽을 읽고 → 어디를 봤는지 말하며 답하듯, 프로그램도 찾기(④) → 전달(⑤) → 작성(⑥) 순서입니다. 원문 확인(⑦)은 지금 실습에서도 합니다.

다음 → 각 단계에서 무엇이 다음 단계로 넘어가는지 봅니다

각 단계에서 다음 단계로 넘어가는 자료

화살표를 따라 이동하는 자료를 적었습니다. 출처 정보는 ②에서 붙어 끝까지 이어집니다.

이동	넘기는 자료	받는 쪽이 하는 일	이번 실습
① → ②	청크 본문 · 청크 ID · 파일명 · 기간 · 절 제목	프로그램이 각 청크를 임베딩 모델에 보내고, 숫자와 함께 ChromaDB에 저장합니다	NB01 → NB02 (chunks.jsonl)
③ → ④	질문 문장, 사용자가 고른 기간 2025Q3	프로그램이 질문을 숫자로 바꾸고, 기간은 ChromaDB의 검색 조건으로 넘깁니다	NB03
④ → ⑤	후보 청크 최대 5개 + 각 청크의 파일명·기간·절 제목	사람이 후보 원문을 읽습니다. 후속에서는 답변 프로그램이 질문과 함께 묶습니다	NB03(원문 확인) ⑤는 후속 개념
⑤ → ⑥	질문 + 근거 청크 + 출처 정보를 묶은 입력	생성 모델이 근거를 참고해 답변 문장을 씁니다	후속 개념
⑥ → ⑦	답변 문장 + 근거의 파일명·절 제목	사용자가 답변의 금액·기간·단위를 원문과 비교합니다	후속 개념 (원문 비교는 지금도 합니다)

연결 출처(파일명·기간·절)는 ②에서 저장한 정보가 ④ 검색 결과, ⑤ 전달, ⑥ 표시로 이어지는 것입니다.

다음 → 실제 검색 결과가 어떤 모양인지 봅니다

검색 결과는 답변이 아니라 후보 글입니다

ChromaDB는 사용자가 고른 2025Q3 자료에서 후보 글을 최대 5개 돌려줍니다.

기존 저장 결과 NB03의 저장 출력이에요(재실행하지 않음). 표는 원본 값으로 다시 구성했고 거리 값은 생략했습니다.

순위	청크 ID	절 제목
1	2025Q3_0196	III. 재무에 관한 사항 > 2-2. 연결 포괄손익계산서
2	2025Q3_0137	II. 사업의 내용 > 7. 기타 참고사항
3	2025Q3_0142	II. 사업의 내용 > 7. 기타 참고사항
4	2025Q3_0193	III. 재무에 관한 사항 > 1. 요약재무정보
5	2025Q3_0014	II. 사업의 내용 > 2. 주요 제품 및 서비스

1위 청크 2025Q3_0196의 본문 일부

(단위 : 백만원)

	3분기 3개월	3분기 누적
매출액	24,448,929	64,320,022

학생은 이 표에서 질문의 기간(3개월)에 맞는 열과 단위를 읽습니다.

출처(5개 모두 같은 파일): 000660_SK하이닉스_2025Q3_원문발췌_실습용_v1.0.md

프로그램은 후보의 순위, 청크 ID, 출처와 절 제목을 표로 보여 줍니다. 학생은 후보의 본문을 읽고 질문에 필요한 근거가 있는지 확인합니다. **다섯 후보가 모두 정답의 근거라는 뜻은 아닙니다.**

확인 순위 1이 항상 정답 근거인 것은 아닙니다. 학생은 원문의 열 제목과 단위를 직접 읽습니다.

다음 → 이 후보를 답변 모델에 어떻게 넘기는지(후속 개념) 봅니다

답변 모델에 함께 보내는 자료

검색과 답변 작성 사이에 '전달' 단계가 있습니다. 현재 노트북은 이 단계를 실행하지 않습니다.

후속 구성 예 후속 답변 프로그램이 생성 모델에 보낼 수 있는 한 묶음입니다.

생성 모델에 보내는 한 묶음

① 사용자의 질문 "2025년 3분기 3개월간 SK하이닉스의 연결 매출액은 얼마인가요?"

② 찾은 글 조각(청크 2025Q3_0196)의 표 | 매출액 | 24,448,929 (3개월) | 64,320,022 (누적) | (단위 : 백만원)

③ 출처 정보 파일 000660_SK하이닉스_2025Q3_원문발췌_실습용_v1.0.md · 절 III. 재무에 관한 사항 > 2-2. 연결 포괄손익계산서

④ 요청 "제공한 근거를 중심으로 답해 주세요."

후속 답변 프로그램은 사용자의 질문, 찾은 글 조각, 원문 파일명과 절 제목을 함께 보낼 수 있습니다. 프로그램은 생성 모델에 **제공한 근거를 중심으로 답하도록 요청**합니다. 현재 노트북(NB03)이 Ollama에 보내는 요청은 '질문을 숫자 목록으로 바꾸는 요청'이고, 답변을 써 달라는 요청이 아닙니다.

상태 후속 구성 예입니다. NB01~NB05에는 생성 모델에 답변을 요청하는 코드가 없습니다.

다음 → 근거에 맞게 쓴 답변 문장의 모양을 봅니다

답변 문장과 출처를 함께 확인합니다

근거에 맞게 쓴 답변 문장은 이런 모양입니다. 사용자는 금액·기간·단위를 원문과 비교합니다.

답변 문장

SK하이닉스의 2025년 3분기 3개월 연결 매출액은 24,448,929 백만원입니다.

설명용 답변 예 — 현재 노트북의 생성 실행 결과가 아닙니다

연결 포괄손익계산서	제 78 기 3분기 3개월	제 78 기 3분기 누적
매출액	24,448,929	64,320,022

근거 표 · 원문 일부 재구성 · (단위 : 백만원) · 연결 기준

답변 옆에 표시하는 출처

파일 000660_SK하이닉스_2025Q3_원문발췌_실습용_v1.0.md
절 2-2. 연결 포괄손익계산서 · 청크 ID 2025Q3_0196

사용자가 원문과 비교할 세 가지

금액 24,448,929 · 기간 2025년 3분기 3개월 · 단위 백만원 (그리고 '연결' 기준)

생성 모델은 이런 답변 문장을 쓰도록 구성할 수 있습니다. 답변 프로그램은 근거로 사용한 원문 파일명과 '연결 포괄손익계산서' 절을 함께 표시하도록 구성합니다. 위 답변 문장은 작성자가 제공된 원문을 보고 만든 설명용 예입니다.

주의 출처가 표시되어도 답변이 틀릴 수 있습니다. 청크 ID는 원본 문서의 쪽 번호가 아닙니다.

다음 → 찾기·전달·작성에서 무엇이 이동하는지 활동으로 확인합니다

활동 2. 검색·전달·작성에서 이동하는 결과

세 결과를 알맞은 단계에 연결하고, 출처 정보가 어디서 처음 붙는지 설명해 보십시오.

활동

세 단계 (실행 순서대로)

- ④ 후보 글 찾기
- ⑤ 질문·근거 전달하기
- ⑥ 답변 작성·출처 표시

→

세 결과 (순서를 섞었습니다)

- ㄱ. 답변 문장
- ㄴ. 검색된 글 조각과 출처 정보
- ㄷ. 질문과 근거를 묶은 입력

문제 2.

답변 옆에 표시되는 출처(파일명·절 제목)는 ①~⑥ 중 어느 단계에서 **처음** 붙었습니까? 마지막에 저절로 생기는지도 생각해 보십시오.

진행 정답과 이유는 다음 화면에 있습니다.

다음 → 정답과 출처가 이어지는 경로를 확인합니다

해설 2. 출처는 저장할 때 붙인 정보가 이어집니다

해설

단계	결과	이유	영어 이름
④ 후보 글 찾기	ㄴ. 검색된 글 조각과 출처 정보	ChromaDB는 저장한 청크와 출처 정보를 검색 결과로 돌려줍니다.	Retrieval (찾기)
⑤ 질문·근거 전달하기	ㄷ. 질문과 근거를 묶은 입력	후속 답변 프로그램은 질문과 검색 결과를 하나의 입력으로 묶습니다.	Augmented (근거를 함께 넣기)
⑥ 답변 작성·출처 표시	ㄱ. 답변 문장	생성 모델은 그 입력을 참고해 답변 문장을 씁니다. 출처 표시는 답변 프로그램이 합니다.	Generation (답 만들기)

문제 2의 답

출처는 **② 저장 단계**에서 프로그램이 청크에 붙인 정보(파일명·기간·절 제목)입니다. 검색(④)·전달(⑤)·표시(⑥)로 이어 쓰도록 구성합니다. 마지막에 저절로 생기는 것이 아닙니다. ‘Augmented’는 별도 프로그램이나 자동 검증 기능이 아니라 ‘질문에 근거를 함께 넣는다’는 뜻입니다.

이름 Retrieval-Augmented Generation의 머리글자가 RAG입니다. 뜻은 위의 한글 설명이 먼저입니다.

다음 → 답변 모양을 바꾸는 일과 문서를 찾는 일이 어떻게 다른지 봅니다

지시문을 바꾸는 일과 문서를 찾는 일은 다릅니다

개발자가 원하는 일에 따라 먼저 살펴볼 방법이 다릅니다. 세 방법은 함께 쓰일 수도 있습니다.

원하는 일	먼저 살펴볼 방법	이번 실습과의 관계
답변 모양을 바꾸고 싶습니다 (예: 금액·기간·출처 순서로 쓰기)	개발자는 생성 모델에 주는 **지시문과 출력 예시**를 먼저 바꿉니다.	후속 개념. 이번 노트북에는 답변용 지시문이 없습니다.
답에 필요한 문서 내용을 찾고 싶습니다	프로그램은 **검색**을 사용합니다. 청크를 저장해 두고 질문으로 후보를 찾습니다.	현재 실습(NB01~NB05)
모델이 답하는 방식 자체를 바꾸고 싶습니다	**모델 추가 학습**은 학습 예제로 모델 내부의 값을 조정하는 별도 작업입니다.	추가 학습은 이번 실습에 없습니다.

답변 형식을 바꾸는 데 반드시 추가 학습이 필요한 것은 아닙니다. 검색·지시문·추가 학습이 서로 동시에 쓰일 수 없는 선택지도 아닙니다.

> **구분** 문서 준비(청크·임베딩·저장)는 모델을 학습시키는 일이 아닙니다. 검색 자료를 만드는 일입니다.

다음 → 그 준비 단계가 실제로 어떤 파일을 만드는지 봅니다

프로그램은 질문 전에 검색 자료를 준비합니다

준비 단계의 입력·처리·결과입니다. 노트북 사이는 저장한 파일로 이어집니다.

MD 파일 5개
rag_exam/data 폴더의 실습용 분기보고서 MD 파일 원문

→

NB01 문서를 청크로 나누기
프로그램이 MD를 읽고 청크를 만듭니다

→

artifacts/chunks.jsonl
청크 800개 (본문·ID·파일명·기간·절)

→

NB02 임베딩과 ChromaDB 저장
임베딩 모델이 숫자를 만들고, 프로그램이 청크·숫자·출처를 저장합니다

→

chroma_db + index.json
컬렉션 skhynix_basic · 모델 이름 등 설정

프로그램은 처음 준비할 때 MD 파일을 읽고 청크를 만듭니다. 임베딩 모델은 각 청크를 숫자 목록으로 바꾸고, 프로그램은 청크·숫자·출처 정보를 ChromaDB에 저장합니다. **문서가 바뀌면 프로그램은 검색 자료도 다시 준비해야 합니다.**

이 과정은 검색 자료를 준비하는 일입니다. 프로그램이 임베딩 모델을 다시 학습시키는 것은 아닙니다.

NB02를 다시 실행하면 프로그램은 skhynix_basic 컬렉션을 비우고 현재 청크 전체를 다시 저장합니다. 바뀐 문서만 골라 갱신하는 구현이 아닙니다.

시점 ‘처음 한 번만’이 아닙니다. 처음 준비할 때와 문서가 바뀔 때 다시 합니다.

다음 → 질문이 들어오면 사용자가 실제로 무엇을 입력하는지 봅니다

사용자는 질문과 기간을 따로 입력합니다

NB03(03_ChromaDB에서_근거_조회.ipynb)의 실제 코드입니다. 사용자가 적는 값은 두 개입니다.

직접 캡처 NB03 코드 4번 셀을 실행하지 않고 노트북 화면에서 직접 캡처했어요(오른쪽 빈 여백만 잘라냈습니다).

In [4]:
```
# 찾고 싶은 내용을 질문 문장으로 적습니다. 정답 금액을 검색어에 넣지 않습니다.
question = "2025년 3분기 3개월간 SK하이닉스의 연결 매출액은 얼마인가요?"
# 사용자가 선택하는 기간 조건입니다. 질문을 자동 분석해 만든 값이 아닙니다.
period = "2025Q3"
```

question
궁금한 내용을 질문 문장으로 적습니다. 정답 금액은 넣지 않습니다.

period
사용자가 고른 조회 기간입니다. 2025Q3는 2025년 3분기 분기 보고서를 뜻합니다. 프로그램이 질문을 보고 만든 값이 아닙니다.

프로그램이 질문을 문서와 같은 임베딩 모델로 숫자 목록으로 바꿉니다 → ChromaDB가 period 조건에 맞는 글에서 후보를 찾습니다 → 사용자가 후보의 원문을 확인합니다

확인 기간은 사용자가 고르는 조건입니다. 질문을 읽어 기간을 자동으로 뽑는 기능은 이번 노트북에 없습니다.

다음 → 같은 매출액 행에서 읽을 열이 어떻게 달라지는지 봅니다

같은 매출액 행에서도 읽을 열이 다릅니다

질문의 기간과 표의 열을 연결합니다. 단위와 '연결' 기준도 답에 남깁니다.

원문 일부 재구성 제공된 실습용 원문의 2-2. 연결 포괄손익계산서

보고 기간 2025.01.01 ~ 2025.09.30 · (단위 : 백만원)

연결 포괄손익계산서	제 78 기 3분기 3개월	제 78 기 3분기 누적
매출액	24,448,929	64,320,022

↑ 질문이 '3분기 3개월간'이므로 이 열을 읽습니다

↑ 1~9월 누적. 질문과 다른 기간입니다

학생이 읽는 순서

① 표 제목에서 '연결' 기준을 확인합니다.

② 단위 '백만원'을 확인합니다.

③ 질문의 기간 '3개월'과 같은 열을 고릅니다.

④ 매출액 행에서 24,448,929를 읽습니다.

표는 3개월 매출액 24,448,929와 누적 매출액 64,320,022를 함께 보여 줍니다. 사용자의 질문은 3분기 3개월이므로 학생은 3개월 열을 읽습니다. 학생은 '연결' 기준과 '백만원' 단위도 답변에 함께 남겨야 합니다. **"매출액은 24,448,929입니다"처럼 단위와 기간을 빼고 적으면 다른 기간·다른 단위의 값과 구별할 수 없습니다.**

주의 표 위의 보고 기간 2025.01.01~2025.09.30만 보고 모든 열이 누적이라고 읽지 않습니다. '3개월' 열과 '누적' 열을 각각 읽습니다.

다음 → 검색 결과가 있어도 남는 확인 사항을 봅니다

검색 결과가 있어도 확인할 일이 남습니다

‘신뢰성’이라는 말 대신, 겪는 상황과 다음 행동을 연결했습니다.

겪는 상황	학생·사용자가 확인할 행동
검색된 후보 5개에 필요한 근거가 없습니다	질문의 기간(period)과 원문을 다시 확인합니다. “지금 찾은 자료만으로는 답을 확인하기 어렵습니다”라고 답을 보류합니다. 원문에 답이 없다고 바로 단정하지는 않습니다.
다음 분기 보고서가 나왔습니다	프로그램이 검색 자료(청크·저장)를 다시 준비해야 합니다. 다시 준비하지 않으면 옛 청크가 그대로 검색됩니다.
생성 모델을 연결했는데 답변의 숫자가 표와 다릅니다	사용자는 답변의 금액·기간·단위를 원문과 비교합니다. 출처가 붙어 있어도 답변이 틀릴 수 있습니다.
회사 내부 자료를 검색 대상에 넣고 싶습니다	사용자가 읽을 수 있는 자료인지 확인하는 접근 권한은 별도 설계 항목입니다. 이번 노트북에는 없습니다.

정리 현재 노트북은 답변 보류나 접근 통제를 자동으로 하지 않습니다. 확인하는 사람은 학생과 사용자입니다.

다음 → 지금까지 본 내용을 실제 자료로 확인해 봅니다

활동 3. 실제 자료로 전체 흐름 확인하기

필요한 질문·표·출처는 이 화면 안에 있습니다. 앞 화면을 찾아가지 않아도 풀 수 있습니다.

활동

1. '문서 나누기와 저장'이 필요한 시점과 '질문 임베딩과 검색'이 필요한 시점을 나누어 보십시오.
2. 아래 질문에서 사용자가 입력할 period 값을 적어 보십시오.
3. 아래 표에서 질문에 맞는 금액·열 이름·단위를 표시해 보십시오.
4. "NB03이 답변 문장을 생성했다"는 설명이 맞는지, NB03의 결과(후보 표와 원문)와 비교해 판단해 보십시오.
5. 검색한 후보에 근거가 없을 때 먼저 확인할 사항을 하나 적어 보십시오.

활동에 쓸 자료

질문 "2025년 3분기 3개월간 SK하이닉스의 연결 매출액은 얼마인가요?"

표(원문 일부 재구성, 단위 : 백만원, 연결 기준)

| 매출액 | 3분기 3개월 24,448,929 | 3분기 누적 64,320,022 |

출처 000660_SK하이닉스_2025Q3_원문발췌_실습용_v1.0.md · 2-2. 연결 포괄손익계산서

NB03의 결과 후보 표 5행(순위·청크 ID·절·출처)과 1위 청크 2025Q3_0196의 원문 표

진행 이 활동은 이 교안의 설명이 충분한지 확인하는 용도입니다. 정답과 이유는 다음 화면에 있습니다.

다음 → 정답과 이유를 확인합니다

해설 3. 숫자와 조건을 함께 읽습니다

해설

1. 프로그램은 **처음 준비할 때와 문서가 바뀔 때** 문서를 나누고 저장해요(NB01·NB02). 프로그램은 **질문이 들어오면** 질문 임베딩과 검색을 진행해요(NB03).

2. 사용자는 period에 **2025Q3**를 입력합니다. 이 값은 사용자가 고르는 조건입니다. 프로그램이 질문에서 자동으로 뽑지 않습니다.

3. 질문에 맞는 값은 **24,448,929백만원**이에요. 이 값은 연결 기준의 '제 78 기 3분기 3개월' 열에 있습니다. 64,320,022백만원은 1~9월 누적 값이라 질문의 기간과 다릅니다.

4. 맞지 않습니다. NB03은 저장된 원문을 찾아 표로 보여 줍니다. **NB03은 생성 모델로 답변 문장을 쓰지 않습니다.** 답을 읽는 사람은 학생입니다.

5. 사용자는 질문의 기간, 찾아온 원문, 검색 자료가 준비되어 있는지를 다시 확인할 수 있습니다. 검색 순위만으로 원문에 답이 없다고 확정할 수는 없습니다.

마무리 정답 숫자만이 아니라 '왜 그 열인지'를 말할 수 있으면 이 교안의 목표에 도달한 것입니다.

여기까지가 개요입니다. 다음은 설치 교안(3.ollama_install.pptx)으로 이어집니다.